

TEMA 1 Introducción

1.1 Conceptos básicos de la inferencia estadística

Def: (Muestra aleatoria)

X v.a.

La contaminación por cobre. Variable, pues en cada punto puede haber una contaminación distinta.

Luego una muestra aleatoria de X es un conjunto X_1, \dots, X_n i.i.d.

En la práctica tenemos una observación de X_1, \dots, X_n , x_1, \dots, x_n , que es una realización muestral.

Observación

Nos podemos hacer varias preguntas

- $E(X) = \mu?$ → Cont. media de cobre. Est. puntual
- $E(C(\mu; 0.95))?$ → Estimación por Int. de conf. o zóquiles
- $H_0: \mu = 20?$ → Contraste de hipótesis.

Con estos conocimientos debemos responder a las preguntas que nos formulamos. Usando la realización muestral.

Usted no solo obtendría una única variable ni no que queremos estudiar más por ejemplo X_1, X_2, X_3

Co $\begin{cases} X_1 \equiv \text{cont. cobre} \\ X_2 \equiv \text{cont. hierro} \\ X_3 \equiv \text{cont. Pb. restón} \end{cases}$

$$\Rightarrow \underline{X} = \begin{pmatrix} X_1 \\ X_2 \\ X_3 \end{pmatrix}$$

no ahora me plantea el problema con el vector \underline{X} y luego un estudio de las 3 variables a la vez.

Se puede hacer un estudio de cada variable de forma individual. Pero esto presenta algunos inconvenientes:

- 1) Se pierde toda la relación que pueden existir entre las variables. No es exactamente que se pierde, sino, que con el estudio individual no se tiene en cuenta.
- 2) En los contrastes de hipótesis es acumulada la propia probabilidad de error de tipo I.

$$\textcircled{1} s_c^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$$

$$\textcircled{2} s^2 = \frac{(n-1)}{n} \sum (x_i - \bar{x})^2$$

$$\textcircled{3} \bar{x} = \frac{1}{n} \sum x_i$$

1.2. Dos muestras aleatorias relacionadas

(P) $\left\{ \begin{array}{l} \bar{X} = \text{cont. por cobre en la superficie} \\ \bar{Y} = \text{cont. por cobre en 10 cm.} \end{array} \right\} \rightarrow \text{Tengo una muestra de la para } \begin{pmatrix} \bar{X} \\ \bar{Y} \end{pmatrix}$

Non podemos plantear el contraste de hip. $H_0: \mu_x = \mu_y$.

$\rightarrow D := \bar{X} - \bar{Y} \rightarrow H_0: \mu_D = 0 \quad (\Rightarrow) \quad H_0: \mu_y = \mu_x$
 $\mu_x - \mu_y = 0$

\hookrightarrow Me puede plantear el problema de 1 variable y aplicar lo mismo que en el caso 1-dimensional.

Recordemos ...

Sobre una m.a $\bar{X}_1, \dots, \bar{X}_m$ (i.i.d. a \bar{X}) existien 2 estadisticos fundamentales:

- $\bar{\bar{X}} = \frac{1}{m} \sum_{k=1}^m \bar{X}_k$
- $S_c^2 = \frac{1}{m-1} \sum_{k=1}^m (\bar{X}_k - \bar{\bar{X}})^2 = \frac{m}{m-1} S^2 \quad (= \frac{1}{m} \sum \bar{X}_k^2 - \bar{\bar{X}}^2)$

$\bar{\bar{X}}$ y S_c^2 son estimadores insesgados de μ y σ^2 respectivamente, pues $E(\bar{\bar{X}}) = \mu$
 $y E(S_c^2) = \sigma^2 \quad (E(S^2) = \frac{\sigma^2}{m} \Rightarrow E(mS^2) = \sigma^2)$

1.3 Características poblacionales y muestras aleatorias

Caso p-dimensional $\underline{\bar{X}} = \begin{bmatrix} \bar{X}_1 \\ \vdots \\ \bar{X}_p \end{bmatrix} = [\bar{X}_1, \dots, \bar{X}_p]'$

1.3.1 Características (Parameters) poblacionales

\hookrightarrow Vector de medias $E(\underline{\bar{X}}) = \begin{bmatrix} E(\bar{X}_1) \\ \vdots \\ E(\bar{X}_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_p \end{bmatrix} = \underline{\mu}$

\hookrightarrow Matriz de varianzas y covarianzas (MVC)

$\sigma_{jk} = \text{cov}(\bar{X}_j, \bar{X}_k) = E((\bar{X}_j - \mu_j)(\bar{X}_k - \mu_k))$

$\sigma_j^2 = \sigma_{jj} = \text{cov}(\bar{X}_j, \bar{X}_j) = \text{Var}(\bar{X}_j)$

$\Sigma = \text{cov}(\underline{\bar{X}}) = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \dots & \sigma_{pp} \end{bmatrix} = [\sigma_{jk}], j, k = 1, \dots, p.$

(MVC es simetrica
 pues $\text{Cov}(\bar{X}, \bar{X}) = \text{Cov}(\bar{X}, \bar{X})$)

Mat. de correlaciones

$$\rho_{jk} = \frac{\sigma_{jk}}{\sigma_j \sigma_k}, \quad \rho_{jj} = 1; \quad R := \text{Mat. de correlaciones} = (\rho_{jk})_{j,k=1,\dots,p}$$

• $R = \Delta^{-1} \Sigma \Delta^{-1}$ con $\Delta \equiv \text{diag}[\sigma_1, \dots, \sigma_p]$.

Nota

- ① $V(X) = E[(X - \mu)^2] = E(X^2) - \mu^2$
- ② $\text{Cov}(X, Y) = E[(X - \mu_x)(Y - \mu_y)] = E(XY) - E(X)E(Y) = \text{Cov}(Y, X)$
- ③ Coefficiente de correlación lineal entre X e Y

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Propiedades

• $\rho \in [-1, 1]$

• $\rho^2 \in [0, 1]$

• El signo de ρ depende de $\text{Cov}(X, Y)$

• $\rho^2 = 0 \Leftrightarrow X, Y$ son independientes ($\text{Cov}(X, Y) = 0$)

• X, Y ind $\Rightarrow X, Y$ independientes

• X, Y ind $\Rightarrow X, Y$ independientes \rightarrow Normal Multivariada.

• $\rho^2 = 1 \Leftrightarrow \exists a, b \mid Y = a + bX$

El coeficiente de correlación lineal mide cuánto relación lineal existe entre X e Y .

④ R es simétrica

⑤ Elementos básicos de un vector \underline{X}

- Vector de Medias
- Mat. v. c
- Mat. de correlaciones.

1.3.2 Vector de variables estandarizadas

$$\underline{Z}(s) = \begin{bmatrix} \frac{X_1 - \mu_1}{\sigma_1} \\ \vdots \\ \frac{X_p - \mu_p}{\sigma_p} \end{bmatrix} = \Delta^{-1} (\underline{X} - \underline{\mu})$$

$$\underline{X} \begin{cases} E(\underline{X}) = \underline{\mu} \\ V(\underline{X}) = \Sigma \end{cases} \sim \underline{Y} = \frac{\underline{X} - \underline{\mu}}{\sigma}$$

$$\Rightarrow \underline{Y} \begin{cases} E(\underline{Y}) = 0 \\ V(\underline{Y}) = \frac{V(\underline{X} - \underline{\mu})}{\sigma^2} = \frac{V(\underline{X})}{\sigma^2} = I \end{cases}$$

Las técnicas estadísticas dependen mucho de la unidad con la que se miden los experimentos. Luego el procedimiento de estandarización es muy usado en la práctica para poder obtener variables a-dimensionales.

La matriz de correlaciones no se ve afectada por la estandarización por la M.V.C. ni.

$$R = \Sigma_{(s)} = R_{(s)}$$

1.3.3 Muestra aleatoria de $\underline{X} \sim (\underline{\mu}, \underline{\Sigma})$

→ $\underline{X}_1, \dots, \underline{X}_m$ i.i.d a \underline{X} .

• Elementos muestrales

$$\underline{X}_i = \begin{bmatrix} X_{i1} \\ \vdots \\ X_{ip} \end{bmatrix} \quad \underline{X}_i^t = (X_{i1}, \dots, X_{ip}), i = 1, \dots, m.$$

→ Matriz (aleatoria) de datos muestrales

Importante → $\underline{X}_{m \times p} = \begin{bmatrix} \underline{X}_1^t \\ \vdots \\ \underline{X}_m^t \end{bmatrix} = \begin{bmatrix} \underline{X}_{11} & \dots & \underline{X}_{1p} \\ \vdots & & \vdots \\ \underline{X}_{m1} & \dots & \underline{X}_{mp} \end{bmatrix}$

→ Matriz de datos

- Tantas filas como elementos haya en la muestra
- Tantas columnas como variables

Data correspondiente a la variable 1 Data corresp. a la variable p.

- X_{ij} es independiente de X_{kt} , para $i \neq k$
- X_{ij} no es independiente de X_{it}

Nota

- Dos elementos de una fila no tienen porque ser independientes pues son copuestos del vector base \underline{X} .
- Dos elementos de distintas columnas sí son indep. al ser $\underline{X}_1, \dots, \underline{X}_m$ m.a.
- La columna i es un m.e. de \underline{X}_i
- Y la matriz aleatoria es un M.e. de \underline{X}

1.4. Estadísticas muestrales


1.4.1 Vector de medias

Importante → $\bar{\underline{X}} = \frac{1}{m} \sum_{i=1}^m \underline{X}_{ij} = \begin{bmatrix} \frac{1}{m} \sum_{i=1}^m X_{i1} \\ \vdots \\ \frac{1}{m} \sum_{i=1}^m X_{ip} \end{bmatrix} = \begin{bmatrix} \bar{X}_1 \\ \vdots \\ \bar{X}_p \end{bmatrix}$

→ Buen estimador de $\underline{\mu}$

Propiedades

$$\sum_{i=1}^m (\underline{X}_i - \bar{\underline{X}}) = \underline{0} \quad \text{no importa cómo que está en el medio}$$



1.4.2 Matriz de varianzas y productos cruzados (S.C.P.C)

→ Varianzas

$$S_{jj} = \sum_{i=1}^m (X_{ij} - \bar{X}_j)^2 \quad i \leq j \leq p$$

1.4.4 Matriz de covarianzas muestrales

6

① (Vari-) Varianza muestral de la j -ésima componente

$$\hat{\sigma}_j^2 = \hat{\sigma}_{jj} = \frac{1}{n-1} \sum_{i=1}^m (\bar{X}_{ij} - \bar{\bar{X}}_j)^2 = \frac{1}{n-1} S_{jj} \quad 1 \leq j \leq p.$$

② (Covari-) covarianza muestral entre las componentes j y k .

$$\hat{\sigma}_{jk} = \frac{1}{n-1} \sum_{i=1}^m (\bar{X}_{ij} - \bar{\bar{X}}_j)(\bar{X}_{ik} - \bar{\bar{X}}_k) = \frac{1}{n-1} S_{jk} \quad 1 \leq j \neq k \leq p.$$

③ MATRIZ DE VARIANZAS Y COVARIANZAS MUESTRALES.

$$\hat{\Sigma} = (\hat{\sigma}_{jk})_{j,k=1,\dots,p}.$$

* $\hat{\Sigma}_{p \times p}$ es simétrica semidefinida positiva (con prob. 1)

$$* \quad \boxed{\hat{\Sigma} = \frac{1}{n-1} S.}$$

1.4.5 Matriz de correlaciones muestrales

→ Matriz de correlaciones poblacionales y correlaciones poblacionales.

$$\rho_{jk} = \frac{\sigma_{jk}}{\sigma_j \sigma_k} \quad ; \quad \rho_{jj} = 1.$$

$$R = (\rho_{jk})_{1 \leq j,k \leq p} = \Delta^{-1} \Sigma \Delta^{-1}.$$

↳ Correlaciones muestrales

$$\hat{\rho}_{jk} = \frac{\hat{\sigma}_{jk}}{\hat{\sigma}_j \hat{\sigma}_k} \quad ; \quad \hat{\rho}_{jj} = 1.$$

$$\hat{R} = \hat{\Delta}^{-1} \hat{\Sigma} \hat{\Delta}^{-1} \quad ; \quad \hat{\Delta} = \text{diag}\{\hat{\sigma}_1, \dots, \hat{\sigma}_p\}.$$

Linea de produccion cruzados

$$s_{jk} = \sum_{i=1}^m (\bar{x}_{ij} - \bar{\bar{x}}_j)(\bar{x}_{ik} - \bar{\bar{x}}_k) \quad i \leq j \neq k \leq p. \rightarrow \text{Buen estimador de } \Sigma$$

Matriz s.e.p.c.

$$S = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1p} \\ s_{21} & s_{22} & \dots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \dots & s_{pp} \end{bmatrix} = [s_{jk}]$$

$$S = \sum_{i=1}^m (\underline{\bar{x}}_i - \underline{\bar{\bar{x}}})(\underline{\bar{x}}_i - \underline{\bar{\bar{x}}})^t = \sum_{i=1}^m \underline{\bar{x}}_i \underline{\bar{x}}_i^t - m \underline{\bar{\bar{x}}} \underline{\bar{\bar{x}}}^t =$$

$$S = \tilde{\underline{\bar{X}}}^t \tilde{\underline{\bar{X}}} = \underline{\bar{X}}^t H \underline{\bar{X}}$$

Nota

$$\left(\begin{pmatrix} \bar{x}_1 \\ \bar{y}_1 \end{pmatrix}, \dots, \begin{pmatrix} \bar{x}_n \\ \bar{y}_n \end{pmatrix} \right) (\bar{x}_i - \bar{\bar{x}})(\bar{y}_i - \bar{\bar{y}}) // \text{Cov. muestral} = \frac{\sum_{i=1}^m (\bar{x}_i - \bar{\bar{x}})(\bar{y}_i - \bar{\bar{y}})}{m}$$

Cov. muestral

$$\frac{1}{m} \sum_{i=1}^m (\bar{x}_i - \bar{\bar{x}})(\bar{y}_i - \bar{\bar{y}}) = \frac{1}{m} \sum_{i=1}^m \bar{x}_i \bar{y}_i - \bar{\bar{x}} \bar{\bar{y}} \\ = \overline{\bar{x} \bar{y}} - \bar{\bar{x}} \bar{\bar{y}}$$

Coef. de correlacion lineal muestral

$$\frac{\overline{\bar{x} \bar{y}} - \bar{\bar{x}} \bar{\bar{y}}}{S_{\bar{x}}^2 S_{\bar{y}}^2} // \rho = \frac{\text{Cov}(\bar{x}, \bar{y})}{\sigma_{\bar{x}} \sigma_{\bar{y}}}$$

1.4.3 Matriz de datos centrados

$$\tilde{\underline{\bar{X}}} = \begin{bmatrix} \bar{x}_{11} - \bar{\bar{x}}_1 & \bar{x}_{12} - \bar{\bar{x}}_2 & \dots & \bar{x}_{1p} - \bar{\bar{x}}_p \\ \bar{x}_{21} - \bar{\bar{x}}_1 & \bar{x}_{22} - \bar{\bar{x}}_2 & \dots & \bar{x}_{2p} - \bar{\bar{x}}_p \\ \vdots & \vdots & \ddots & \vdots \\ \bar{x}_{m1} - \bar{\bar{x}}_1 & \bar{x}_{m2} - \bar{\bar{x}}_2 & \dots & \bar{x}_{mp} - \bar{\bar{x}}_p \end{bmatrix} = \begin{bmatrix} \underline{\bar{x}}_1^t - \underline{\bar{\bar{x}}}^t \\ \underline{\bar{x}}_2^t - \underline{\bar{\bar{x}}}^t \\ \vdots \\ \underline{\bar{x}}_m^t - \underline{\bar{\bar{x}}}^t \end{bmatrix}$$

Importante.

$$\textcircled{1} \tilde{\underline{\bar{X}}} = \underline{\bar{X}} - \underline{1}_m \underline{\bar{\bar{x}}}^t = \underline{\bar{X}} - \frac{1}{m} \underline{1}_m \underline{1}_m^t \underline{\bar{X}} = \underline{\bar{X}} - \frac{1}{m} E_m \underline{\bar{X}} = \underbrace{\left[I_m - \frac{1}{m} E_m \right]}_H \underline{\bar{X}} \\ \Rightarrow \tilde{\underline{\bar{X}}} = H \underline{\bar{X}}. ; H \text{ es simetrica e idempotente } (H^2 = H)$$

1.4.6 Elementos estandarizados

(7)

① Vector de variables estandarizadas.

$$\underline{X}_{(S)} = \begin{bmatrix} \frac{X_1 - \mu_1}{\sigma_1} \\ \vdots \\ \frac{X_p - \mu_p}{\sigma_p} \end{bmatrix} = \Delta^{-1} (\underline{X} - \underline{\mu})$$

$\Delta = \text{diag}(\sigma_1, \dots, \sigma_p)$

② Vector de Datos estandarizados

$$\underline{X}_{i(S)} = \begin{bmatrix} \frac{X_{i1} - \bar{X}_1}{\hat{\sigma}_1} \\ \vdots \\ \frac{X_{ip} - \bar{X}_p}{\hat{\sigma}_p} \end{bmatrix} = \hat{\Delta}^{-1} (\underline{X}_i - \bar{\underline{X}})$$

③ Matriz de datos estandarizados

$$\underline{X}_{(S)} = \begin{bmatrix} \frac{X_{11} - \bar{X}_1}{\hat{\sigma}_1} & \frac{X_{12} - \bar{X}_2}{\hat{\sigma}_2} & \dots & \frac{X_{1p} - \bar{X}_p}{\hat{\sigma}_p} \\ \vdots & \vdots & & \vdots \\ \frac{X_{m1} - \bar{X}_1}{\hat{\sigma}_1} & \frac{X_{m2} - \bar{X}_2}{\hat{\sigma}_2} & \dots & \frac{X_{mp} - \bar{X}_p}{\hat{\sigma}_p} \end{bmatrix} = \begin{bmatrix} \underline{X}_1^t - \bar{\underline{X}}^t \\ \vdots \\ \underline{X}_m^t - \bar{\underline{X}}^t \end{bmatrix} \hat{\Delta}^{-1} = \tilde{\underline{X}} \hat{\Delta}^{-1}$$

$$\hat{R} = \hat{\underline{L}}_{(S)} = \hat{R}_{(S)}$$

Esto quiere decir que la matriz de correlaciones muestrales es lo mismo que la Mat. var. cov. muestrales estandarizada.

1.5 Transformaciones lineales

Dada $A_{m \times p}$ y res. $\underline{Y}_{m \times 1} = A \underline{X}_{p \times 1}$ \rightarrow muestra transformada $\underline{Y}_1, \dots, \underline{Y}_m$ con $\underline{Y}_i = A \underline{X}_i$

① $\underline{\bar{Y}} = A \bar{\underline{X}}$

② $S_{\underline{Y}} = A S_{\underline{X}} A^t$

$$\hat{\underline{L}}_{\underline{Y}} = A \hat{\underline{L}}_{\underline{X}} A^t$$

Prueba

$$\textcircled{1} \quad \frac{1}{n} \sum_{i=1}^m \underline{Y}_{ij} = \frac{1}{n} \sum_{i=1}^m \Delta \underline{X}_{ij} \\ = \frac{1}{n} A \sum_{i=1}^m \underline{X}_{ij} = A \begin{pmatrix} \bar{X}_1 \\ \vdots \\ \bar{X}_p \end{pmatrix} = A \bar{\underline{X}}$$

$$\textcircled{2} \quad S_Y = \sum_{i=1}^m (\underline{Y}_i - \bar{\underline{Y}})(\underline{Y}_i - \bar{\underline{Y}})^t \\ \stackrel{A \underline{X}_i \quad A \bar{\underline{X}}}{=} \sum_{i=1}^m (A \underline{X}_i - A \bar{\underline{X}})(A \underline{X}_i - A \bar{\underline{X}})^t \\ = A \sum_{i=1}^m (\underline{X}_i - \bar{\underline{X}})(\underline{X}_i - \bar{\underline{X}})^t A^t = A \hat{\underline{\Sigma}}_X A^t$$

Análogo para $\hat{\underline{\Sigma}}_Y = A \hat{\underline{\Sigma}}_X A^t$ ya que $\hat{\underline{\Sigma}} = \frac{1}{n-1} S \quad \square$

1.6 Matrices Aleatorias

Def: Sea $\{Z_{ij}, i=1, \dots, m; j=1, \dots, g\}$ un conjunto de v.a.

\Rightarrow Matriz aleatoria $\rightarrow \underline{Z} = \begin{bmatrix} Z_{11} & Z_{12} & \dots & Z_{1g} \\ \vdots & \vdots & & \vdots \\ Z_{m1} & Z_{m2} & \dots & Z_{mg} \end{bmatrix} = [Z_{ij}]$

1.6.1 Operadores Esperanza. Propiedades

Def: (Matriz esperanza o matriz de medias)

$$E[\underline{Z}] = \begin{bmatrix} E[Z_{11}] & \dots & E[Z_{1g}] \\ \vdots & & \vdots \\ E[Z_{m1}] & \dots & E[Z_{mg}] \end{bmatrix} = [E(Z_{ij})]$$

Lema 1.6.1.1

Sea \underline{Z} e \underline{Y} dos matrices aleatorias de la misma dimensión. Sean A, B y C matrices constantes de las dimensiones adecuadas.

$\textcircled{1} \quad E[A \underline{Z} B + C] = A E[\underline{Z}] B + C.$

$\textcircled{2} \quad E[\underline{Z} + \underline{Y}] = E[\underline{Z}] + E[\underline{Y}].$

Lema 1.6.1.2

Sea $\underline{X} \sim (\underline{\mu}, \underline{\Sigma})$

$$\textcircled{1} \quad \underline{\Sigma} = E((\underline{X} - E(\underline{X}))(\underline{X} - E(\underline{X}))^t) = E[\underline{X}\underline{X}^t] - \underline{\mu}\underline{\mu}^t$$

Prueba

$$(\underline{X} - \underline{\mu})(\underline{X} - \underline{\mu})^t$$

matriz $p \times p$ ~ sus elementos $(j,k) \rightarrow (X_j - \mu_j)(X_k - \mu_k)$

$$\Rightarrow E((\underline{X} - \underline{\mu})(\underline{X} - \underline{\mu})^t) = [E(j,k)]$$

$$E((X_j - \mu_j)(X_k - \mu_k)) = \sigma_{jk} \quad \square$$

$$\begin{aligned} E[(\underline{X} - \underline{\mu})(\underline{X} - \underline{\mu})^t] &= E[\underline{X}\underline{X}^t - \underline{X}\underline{\mu}^t - \underline{\mu}\underline{X}^t + \underline{\mu}\underline{\mu}^t] \\ &= E(\underline{X}\underline{X}^t) - \underbrace{E(\underline{X})\underline{\mu}^t}_{\underline{\mu}\underline{\mu}^t} - \underline{\mu}(E(\underline{X}^t)) + \underline{\mu}\underline{\mu}^t = \underbrace{E(\underline{X}\underline{X}^t) - \underline{\mu}\underline{\mu}^t}_{\underline{\Sigma}} \end{aligned}$$

$$V(\underline{X}) = E(\underline{X}^t) - \underline{\mu}^t$$

$$\textcircled{2} \quad E(A\underline{X} + \underline{b}) = AE[\underline{X}] + \underline{b}$$

$$\textcircled{3} \quad \text{Cov}(A\underline{X} + \underline{b}) = \underline{\Sigma}_{A\underline{X} + \underline{b}} = A\underline{\Sigma}A^t$$

Prueba

$$A = [a_{ij}], \quad \underline{b} = (b_i) \quad \underline{Y} = A\underline{X} + \underline{b}$$

$$\begin{aligned} E \underline{\Sigma}_{\underline{Y}} &= E((\underline{Y} - \underline{\mu}_{\underline{Y}})(\underline{Y} - \underline{\mu}_{\underline{Y}})^t) = E[A(\underline{X} - \underline{\mu}_{\underline{X}})(\underline{X} - \underline{\mu}_{\underline{X}})^t A^t] = \\ &= A \underline{\Sigma}_{\underline{X}} A^t \end{aligned}$$

$$\textcircled{4} \quad \text{En particular para } \underline{c} \in \mathbb{R}^p$$

$$E(\underline{c}^t \underline{X}) = \underline{c}^t \underline{\mu}$$

$$\text{Var}(\underline{c}^t \underline{X}) = \underline{c}^t \underline{\Sigma} \underline{c}$$

$$\textcircled{5} \quad \underline{\Sigma} \text{ es semidefinida positiva. } (\underline{\Sigma} \geq 0)$$

Prueba

$$\left\{ \begin{array}{l} \text{Dado cualquier } \underline{c} \sim \underline{c}^t \underline{\Sigma} \underline{c} \geq 0 \text{ como } \underline{c}^t \underline{\Sigma} \underline{c} = \text{Var}[\underline{c}^t \underline{X}] \geq 0 \\ \Rightarrow \underline{\Sigma} \text{ es semidefinida positiva.} \end{array} \right.$$

Esto es una cantidad positiva
Menos es la Var. de una V.a.

Def: (Mat. de cov.)

Soit \underline{X} et \underline{Y} des vecteurs aléatoires. Se définit la matrice de covariances entre \underline{X} et \underline{Y} =

$$\text{Cov}(\underline{X}, \underline{Y}) = [\text{Cov}(X_i, Y_j)]$$

Lemme 1.6.1.3

① Si \underline{X} et \underline{Y} sont indépendants $\Rightarrow \text{Cov}(\underline{X}, \underline{Y}) = 0_{p \times q}$

② $\text{Cov}(\underline{X}) = \text{Cov}(\underline{X}, \underline{X}) = \Sigma_{\underline{X}}$

③ $\text{Cov}(\underline{X}, \underline{Y}) = E[(\underline{X} - E(\underline{X}))(\underline{Y} - E(\underline{Y}))^t]$

④ $\text{Cov}(\underline{X}, \underline{Y}) = \text{Cov}(\underline{Y}, \underline{X})^t$

⌋ Preuve

$$\underline{X} + \underline{Y} = \underline{Z} \quad E_{\underline{Z}} = E[(\underline{Z} - \mu_{\underline{Z}})(\underline{Z} - \mu_{\underline{Z}})^t] = E[(\underline{X} - \mu_{\underline{X}} + \underline{Y} - \mu_{\underline{Y}})(\underline{X} - \mu_{\underline{X}} + \underline{Y} - \mu_{\underline{Y}})^t]$$

$$= \Sigma_{\underline{X}} + \underbrace{E[(\underline{X} - \mu_{\underline{X}})(\underline{Y} - \mu_{\underline{Y}})^t]}_{\text{Cov}(\underline{X}, \underline{Y})} + \underbrace{E[(\underline{Y} - \mu_{\underline{Y}})(\underline{X} - \mu_{\underline{X}})^t]}_{\text{Cov}(\underline{Y}, \underline{X})} + \Sigma_{\underline{Y}}$$

⑤ $\text{Cov}(A\underline{X} + c, B\underline{Y} + d) = A \text{Cov}(\underline{X}, \underline{Y}) B^t$

⑥ $\text{Cov}(\underline{X}_1 + \underline{X}_2, \underline{Y}) = \text{Cov}(\underline{X}_1, \underline{Y}) + \text{Cov}(\underline{X}_2, \underline{Y})$

⑦ Si $p=q \Rightarrow \Sigma_{\underline{X} + \underline{Y}} = \Sigma_{\underline{X}} + \text{Cov}(\underline{X}, \underline{Y}) + \text{Cov}(\underline{Y}, \underline{X}) + \Sigma_{\underline{Y}}$

⑧ $\text{Cov}(\sum_{i=1}^n \underline{X}_i) = \sum_{i=1}^n \Sigma_{\underline{X}_i} + \sum_{i \neq j} \text{Cov}(\underline{X}_i, \underline{X}_j)$

1.7 Propiedades de los estadísticos muestrales

(11)

Proposición 1.7.1

Sea $\underline{X}_1, \dots, \underline{X}_m$ un m.a. de un v.a. \underline{X} p-dim. $\underline{X} \sim (\mu, \Sigma)$

Se verifica:

① $E(\bar{\underline{X}}) = \mu$

② $\text{Cov}(\bar{\underline{X}}) = \frac{1}{m} \Sigma$

③ $E(\hat{\Sigma}) = E\left[\frac{1}{m-1} S\right] = \Sigma$

→ El elemento j de $\bar{\underline{X}}$ es un estimador insesgado de μ_j .

→ El elemento (j,k) de $\hat{\Sigma}$ es un estimador insesgado de σ_{jk} .

Demstración

① $\bar{\underline{X}} = \frac{1}{m} \sum_{i=1}^m \underline{X}_i \rightarrow E(\bar{\underline{X}}) = E\left(\frac{1}{m} \sum_{i=1}^m \underline{X}_i\right) = \frac{1}{m} \sum_{i=1}^m E(\underline{X}_i) = \mu$
 \downarrow v.a. i.i.d. a \underline{X}

② $\Sigma_{\bar{\underline{X}}} = \text{Cov}\left(\frac{1}{m} \sum_{i=1}^m \underline{X}_i\right) = \frac{1}{m^2} \text{Cov}\left(\sum_{i=1}^m \underline{X}_i\right) =$
 $= \frac{1}{m^2} \left\{ \sum_{i=1}^m \Sigma_{\underline{X}_i} + \sum_{i \neq j} \text{Cov}(\underline{X}_i, \underline{X}_j) \right\} = \frac{1}{m} \Sigma_{\underline{X}}$

0 por ser una m.a. ya que son ind.

③ $S = \sum_{i=1}^m \underline{X}_i \underline{X}_i^+ - m \bar{\underline{X}} \bar{\underline{X}}^+$

$E(S) = m E[\underline{X} \underline{X}^+] - m E[\bar{\underline{X}} \bar{\underline{X}}^+] = m \Sigma_{\underline{X}} - m \Sigma_{\bar{\underline{X}}} =$
 $m \left(\Sigma_{\underline{X}} + \cancel{\mu \mu^+} - \Sigma_{\bar{\underline{X}}} - \cancel{E(\bar{\underline{X}}) E(\bar{\underline{X}})^+} \right)$

$= m \Sigma_{\underline{X}} - m \frac{1}{m} \Sigma_{\underline{X}} = \Sigma_{\underline{X}} (m-1)$

$E(S) = \Sigma_{\underline{X}} (m-1) \rightsquigarrow E(\hat{\Sigma}) = E\left[\frac{1}{m-1} S\right] = \Sigma_{\underline{X}} \quad \square$

Def:

① Var. muestr. gen: $|\hat{\Sigma}| = \left| \frac{1}{m-1} S \right|$

② Var. muestr. total: $\text{tr}(\hat{\Sigma}) = \frac{1}{m-1} \text{tr}(S)$

③ Var. muestr. efectiva: $|\hat{\Sigma}|^{1/p} = \frac{1}{m-1} |S|^{1/p}$

TEMA 2

Inferencia en poblaciones normales

12

2.1 Distribución normal.

2.1.1. Caso unidimensional $X \sim N(\mu, \sigma^2)$

$$① f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right); -\infty < x < \infty$$

$$② Z = \frac{X-\mu}{\sigma} \sim N(0,1); E(X)=\mu, V(X)=\sigma^2.$$

$$③ aX+b \sim N(a\mu+b; a^2\sigma^2)$$

$$④ X, Y \text{ ind.} \Rightarrow X+Y \sim N(\mu_X+\mu_Y; \sigma_X^2+\sigma_Y^2)$$

2.1.2. Caso multidimensional

$$① f(\underline{X}) = f(x_1, \dots, x_p) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(\underline{X}-\underline{\mu})^T \Sigma^{-1}(\underline{X}-\underline{\mu})\right\}$$

$-\infty < x_i < \infty; i=1, \dots, p.$

$$② Z = \Sigma^{-1/2}(\underline{X}-\underline{\mu}) \sim N_p(0, \Sigma) \rightarrow E(\underline{X})=\underline{\mu}; V(\underline{X})=\Sigma.$$

$$③ \Delta \underline{X} + \underline{b} \sim N_m(\Delta \underline{\mu} + \underline{b}; \Delta \Sigma \Delta^T)$$

$\Delta_{m \times p}, \underline{X}_{p \times 1}, \underline{b}_{m \times 1}$

$$④ \underline{X} \text{ y } \underline{Y} \text{ i.d.} \Rightarrow \underline{X} + \underline{Y} \sim N_p(\underline{\mu}_X + \underline{\mu}_Y; \Sigma_X + \Sigma_Y)$$

2.2. Dist. Chi-cuadrado y Dist. de Wishart. \rightarrow la distribución de Wishart surge en el caso multidimensional lo que en χ_m^2 en el caso unidimensional.

2.2.1 Dist. Chi-cuadrado

$$① X_1, \dots, X_m \text{ m.a. } N(0, \sigma^2) \Rightarrow \sum_{i=1}^m \frac{X_i^2}{\sigma^2} \sim \chi_m^2; \sum_{i=1}^m X_i^2 \sim \sigma^2 \chi_m^2$$

$$② f_m(x) = \frac{1}{2^{m/2} \Gamma(m/2)} x^{m/2-1} e^{-1/2 x} \sim \chi_m^2 \equiv G\left(\frac{m}{2}, \frac{1}{2}\right) \begin{cases} E(X)=m. \\ V(X)=2m. \end{cases}$$

③ Reproductiva.

2.2.2. Dist. de Wishart

Sea $\underline{X}_1, \dots, \underline{X}_m$ m.a. de $N_p(\underline{0}, \Sigma)$ y sea $\underline{X} = [\underline{X}_1, \dots, \underline{X}_m]^T$

$\Rightarrow \sum_{i=1}^m \underline{X}_i \underline{X}_i^T \sim W_p(m; \Sigma) \rightarrow$ distribución de Wishart p-dim. de m grados de libertad y con vector de escalas Σ .

$$W \sim W_p \Rightarrow E[W] = E\left[\sum_{i=1}^m \underline{X}_i \underline{X}_i^T\right] = \sum_{i=1}^m E[\underline{X}_i \underline{X}_i^T] \stackrel{\text{i.i.d.}}{=} m E[\underline{X} \underline{X}^T] = \Sigma m$$

$$\Sigma = E[(\underline{X}-\underline{\mu})(\underline{X}-\underline{\mu})^T] = E[\underline{X} \underline{X}^T] \text{ para } \underline{\mu} = \underline{0}$$

2.3. Distrib. t-Student y T^2 de Hotelling

2.3.1 D. t-Student

$$\begin{aligned} Z &\sim N(0,1) \\ V &\sim \chi_m^2 \\ \text{independientes} \end{aligned}$$

$$T = \frac{Z}{\sqrt{V/m}} \sim t_m \quad \text{equivalentemente}$$

$$\left[\begin{aligned} T^2 &= m \frac{Z^2}{V} \sim F_{1,m} \\ Z^2 &\sim \chi_1^2 \quad (\mu=0, \sigma=1) \end{aligned} \right]$$

2.3.2 D. T^2 de Hotelling $T^2 \sim T_{p,m}^2$

Sean $\underline{d} \sim N_p(0; \Sigma_p)$ y $W \sim W_p(m, \Sigma_p)$ independientes.

Se denomina T^2 de Hotelling a la distribución del estadístico

$$T^2 = m \underline{d}^T W^{-1} \underline{d} \quad \begin{matrix} 1 \times p & p \times p & p \times 1 \end{matrix} \rightarrow 1 \times 1 \text{ es un escalar. Variable unidimensional.}$$

Nota

- ① $T_{p,m}^2$ es una distribución unidimensional
- ② la T^2 de Hotelling recibe parámetros en la F-de Snedecor.

Lema 2.3.1

Sea $\underline{X} \sim N_p(\mu; \Sigma)$ y $W \sim W_p(m; \Sigma)$ independientes.

Entonces:

$$T^2 = m(\underline{X} - \underline{\mu})^T W^{-1} (\underline{X} - \underline{\mu}) \sim T_{p,m}^2.$$

Prueba

$$\underline{X} \sim N_p(\mu; \Sigma) \Rightarrow \Sigma^{-1/2}(\underline{X} - \mu) \sim N_p(0, I_p)$$

$$W \sim W_p(m; \Sigma) = \sum_{i=1}^m \underline{X}_i \underline{X}_i^T \quad (\underline{X}_i \sim N(0; \Sigma)) \Rightarrow \Sigma^{-1/2} W \Sigma^{-1/2}$$

$$= \sum_{i=1}^m \left(\Sigma^{-1/2} \underline{X}_i \right) \left(\Sigma^{-1/2} \underline{X}_i \right)^T \quad (\text{Entonces siguen } N_p(0, I_p)) \sim W_p(m; I)$$

Entro dentro de este paréntesis
ya tenemos pues es una
matriz simétrica.

$$\Rightarrow m(\underline{X} - \mu)^T \Sigma^{-1/2} \left(\Sigma^{-1/2} W \Sigma^{-1/2} \right)^{-1} \Sigma^{-1/2} (\underline{X} - \mu)$$

$$= m(\underline{X} - \mu)^T W^{-1} (\underline{X} - \mu) \sim T_{p,m}^2$$

Lema 2.3.2

Sea $T^2 \sim T_{p,m}^2$. Se verifica

$$\frac{n-p+1}{mp} T^2 \sim F_{p, m-p+1} \quad \text{equivalente} \quad \left[T^2 \sim \frac{mp}{m-p+1} F_{p, m-p+1} \right]$$

2.4 Estimación de parámetros

Sea $\underline{X}_1, \dots, \underline{X}_n$ una muestra aleatoria de una población $N_p(\underline{\mu}, \Sigma)$

① Vector media muestral $\underline{\bar{X}} = \frac{1}{n} \sum_{i=1}^n \underline{X}_i$

② Mat. sum. cuad. y prod. cruzados.

$$S = \sum_{i=1}^n (\underline{X}_i - \underline{\bar{X}})(\underline{X}_i - \underline{\bar{X}})^t$$

③ Mat. Var. y cov. muestrales.

$$\hat{\Sigma} = \frac{1}{n-1} S.$$

Teorema 2.4.1

① $\underline{\bar{X}} \sim N_p(\underline{\mu}, \frac{1}{n}\Sigma)$

a) $\underline{\bar{X}}$ es un est. insesgado de $\underline{\mu}$.

② $(n-1)\hat{\Sigma} = S \sim W_p(m-1, \Sigma)$

a) $\hat{\Sigma}$ es un est. insesgado de Σ .

③ $\underline{\bar{X}}$ y $\hat{\Sigma}$ son independientes

④ $\underline{\bar{X}}$ y $\tilde{\Sigma} = \frac{1}{n} S$ son eficientes en max. verosimilitud de $\underline{\mu}$ y Σ .