

Tema 1
Resumen: Inferencia en poblaciones normales

Curso 2017-18

1 Distribución normal

1.1 Caso unidimensional: $X \sim N(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}, \quad -\infty < x < \infty$$

1.2 Caso multidimensional: $\underline{X} \sim N_p(\underline{\mu}, \underline{\Sigma})$

$$f(\underline{x}) = f(x_1, \dots, x_p) = \frac{1}{(2\pi)^{p/2} |\underline{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\underline{x} - \underline{\mu})' \underline{\Sigma}^{-1} (\underline{x} - \underline{\mu}) \right\}, \quad -\infty < x_i < \infty, i = 1, \dots, p$$

2 Distribución ji-cuadrado - Distribución Wishart

2.1 Distribución ji-cuadrado

Sea X_1, \dots, X_n una m.a. de $N(0, \sigma^2)$.

$$\sum_{i=1}^n \frac{X_i^2}{\sigma^2} \sim \chi_n^2$$
$$\sum_{i=1}^n X_i^2 \sim \sigma^2 \chi_n^2$$

2.2 Distribución Wishart: $\mathbf{W} \sim W_p(n, \Sigma)$

Sea $\underline{X}_1, \dots, \underline{X}_n$ una m.a. de $N_p(\mathbf{0}, \Sigma)$ y sea $\mathbf{X} = [\underline{X}_1 \dots \underline{X}_n]'$.

La matriz aleatoria $\mathbf{W} = \mathbf{X}'\mathbf{X} = \sum_{i=1}^n \underline{X}_i \underline{X}_i'$ se dice que se distribuye según una **distribución de Wishart** no singular p -dimensional con n grados de libertad y matriz de escala Σ .

$$\sum_{i=1}^n \underline{X}_i \underline{X}_i' \sim W_p(n, \Sigma)$$

3 Distribución t-student - distribución T^2 de Hotelling

3.1 Distribución t-student

Dadas $Z \sim N(0, 1)$ y $V \sim \chi_n^2$, independientes

$$T = \frac{Z}{\sqrt{V/n}} \sim t_n \quad \text{equivalentemente} \quad T^2 = n \frac{Z^2}{V} \sim F_{1,n}$$

3.2 Distribución T^2 de Hotelling: $T^2 \sim T_{p,n}^2$.

Sean $\underline{d} \sim N_p(\underline{\mathbf{0}}, \mathbf{I}_p)$ y $\mathbf{W} \sim W_p(n, \mathbf{I}_p)$ independientes.

Se denomina distribución T^2 de Hotelling a la distribución del estadístico

$$T^2 = n \underline{d}^t \mathbf{W}^{-1} \underline{d},$$

Nota. $T_{p,n}^2$ es una distribución unidimensional.

Lema. Sea $\underline{X} \sim N_p(\underline{\mu}, \mathbf{\Sigma})$ y $\mathbf{W} \sim W_p(n, \mathbf{\Sigma})$ independientes.

Entonces

$$T^2 = n(\underline{X} - \underline{\mu})' \mathbf{W}^{-1} (\underline{X} - \underline{\mu}) \sim T_{p,n}^2$$

Lema. Sea $T^2 \sim T_{p,n}^2$. Se verifica

$$\frac{n-p+1}{np} T^2 \sim \mathcal{F}_{p, n-p+1}$$

o equivalentemente

$$T^2 \sim \frac{np}{n-p+1} \mathcal{F}_{p, n-p+1}.$$

4 Estimación de parámetros

Sea $\underline{X}_1, \underline{X}_2, \dots, \underline{X}_n$ una muestra aleatoria de una población $N_p(\underline{\mu}, \underline{\Sigma})$.

- Vector media muestral: $\overline{\underline{X}} = \frac{1}{n} \sum_{i=1}^n \underline{X}_i$
- Matriz suma de cuadrados y productos cruzados (s.c.p.c.)

$$\mathbf{S} = \sum_{i=1}^n (\underline{X}_i - \overline{\underline{X}}) (\underline{X}_i - \overline{\underline{X}})^t$$

- Matriz de varianzas y covarianzas muestrales

$$\widehat{\underline{\Sigma}} = \frac{1}{n-1} \mathbf{S}$$

Teorema

1. $\overline{\underline{X}} \sim N_p(\underline{\mu}, \frac{1}{n} \underline{\Sigma})$.
 - (a) $\overline{\underline{X}}$ es un estimador insesgado de $\underline{\mu}$.
2. $(n-1) \widehat{\underline{\Sigma}} = \mathbf{S} \sim W_p(n-1, \underline{\Sigma})$
 - (a) $\widehat{\underline{\Sigma}}$ es un estimador insesgado de $\underline{\Sigma}$.
3. $\overline{\underline{X}}$ y $\widehat{\underline{\Sigma}}$ son independientes.
4. $\overline{\underline{X}}$ y $\widetilde{\underline{\Sigma}} = \frac{1}{n} \mathbf{S}$ son los estimadores de máxima verosimilitud de $\underline{\mu}$ y $\underline{\Sigma}$.

5 Contraste de hipótesis sobre el vector de medias de una población.

5.1 Caso univariante

Sea X_1, \dots, X_n una m.a de una $N(\mu, \sigma^2)$, con σ desconocida.

- Estadístico del TRV para contrastar $H_0 : \mu = \mu_0$ versus $H_1 : \mu \neq \mu_0$

$$\frac{\bar{X} - \mu_0}{S_c} \sqrt{n} \quad \text{o bien} \quad n \left(\frac{\bar{X} - \mu_0}{S_c} \right)^2$$

- Distribución del estadístico bajo H_0

$$\frac{\bar{X} - \mu_0}{S_c} \sqrt{n} \stackrel{H_0}{\sim} t_{n-1} \quad \text{o bien} \quad n \left(\frac{\bar{X} - \mu_0}{S_c} \right)^2 \stackrel{H_0}{\sim} \mathcal{F}_{1, n-1}$$

- Región crítica para un test de tamaño α

$$\left| \frac{\bar{X} - \mu_0}{S_c} \right| \sqrt{n} \geq t_{n-1, 1-\alpha/2} \quad \text{o bien} \quad n \left(\frac{\bar{X} - \mu_0}{S_c} \right)^2 \geq \mathcal{F}_{1, n-1, 1-\alpha}$$

5.2 Caso multivariante

Sea $\underline{X}_1, \dots, \underline{X}_n$ una m.a de una población $N_p(\underline{\mu}, \underline{\Sigma})$, con $\underline{\Sigma}$ desconocida

- Estadístico TRV para contrastar las hipótesis $H_0 : \underline{\mu} = \underline{\mu}_0$ vs. $H_1 : \underline{\mu} \neq \underline{\mu}_0$

$$n \left(\overline{\underline{X}} - \underline{\mu}_0 \right)' \widehat{\underline{\Sigma}}^{-1} \left(\overline{\underline{X}} - \underline{\mu}_0 \right) = n(n-1) \left[\overline{\underline{X}} - \underline{\mu}_0 \right]^t \mathbf{S}^{-1} \left[\overline{\underline{X}} - \underline{\mu}_0 \right]$$

- Distribución del estadístico bajo H_0

$$n \left[\overline{\underline{X}} - \underline{\mu}_0 \right]^t \widehat{\underline{\Sigma}}^{-1} \left[\overline{\underline{X}} - \underline{\mu}_0 \right] \stackrel{H_0}{\sim} T_{p, n-1}^2$$

o

$$\frac{n-p}{p} n \left[\overline{\underline{X}} - \underline{\mu}_0 \right]^t \mathbf{S}^{-1} \left[\overline{\underline{X}} - \underline{\mu}_0 \right] \stackrel{H_0}{\sim} \mathcal{F}_{p, n-p}$$

- Región crítica para un test de tamaño α

$$\frac{n-p}{p} n \left[\overline{\underline{X}} - \underline{\mu}_0 \right]^t \mathbf{S}^{-1} \left[\overline{\underline{X}} - \underline{\mu}_0 \right] \geq \mathcal{F}_{p, n-p, 1-\alpha}$$

- Región de confianza al nivel $(1 - \alpha)$ para el vector de medias $\underline{\mu}$

$$\left\{ \underline{\mu} / \frac{n-p}{p} n \left[\overline{\underline{X}} - \underline{\mu} \right]^t \mathbf{S}^{-1} \left[\overline{\underline{X}} - \underline{\mu} \right] \leq \mathcal{F}_{p, n-p, 1-\alpha} \right\}$$

5.3 Contraste y regiones de confianza para transformaciones lineales

Proposición.

Sea $\underline{X}_1, \underline{X}_2, \dots, \underline{X}_n$ una muestra aleatoria de $\underline{X} \sim N_p[\underline{\mu}, \underline{\Sigma}]$.

Sea \mathbf{A} una matriz $m \times p$ ($m \leq p$), de rango m , y \underline{d} un vector m -dimensional .

El estadístico del test de razón de verosimilitudes para el contraste:

$$H_0 : \mathbf{A}\underline{\mu} = \underline{d} \quad vs. \quad H_1 : \mathbf{A}\underline{\mu} \neq \underline{d}$$

viene dado por:

$$T^2 = (n-1)n \left[\mathbf{A}\overline{\underline{X}} - \underline{d} \right]^t \left[\mathbf{A}\mathbf{S}\mathbf{A}^t \right]^{-1} \left[\mathbf{A}\overline{\underline{X}} - \underline{d} \right]$$

y

$$T^2 \stackrel{H_0}{\sim} T_{m,n-1}^2.$$

5.3.1 Diseño para medidas repetidas

- Consideremos n elementos de una población, sobre los que se realizan p medidas de una misma magnitud en p situaciones experimentales distintas.
- Puede considerarse la siguiente modelización:

- $\underline{X} = (X_1, \dots, X_p)'$ medidas de la misma magnitud en p situaciones experimentales distintas.
- $\underline{X} \sim N_p(\underline{\mu}, \underline{\Sigma})$ donde $\underline{\mu} = [\mu_1, \dots, \mu_p]'$.
- $\underline{X}_1, \dots, \underline{X}_n$ m.a. de \underline{X}

- Hipótesis básica : igualdad de medias de la magnitud en todas las situaciones experimentales

$$H_0 : \mu_1 = \dots = \mu_p$$

- Equivalentemente

$$H_0 : \mu_1 - \mu_p = \dots = \mu_{p-1} - \mu_p = 0 \Leftrightarrow H_0 : \mathbf{C}\underline{\mu} = \mathbf{0}$$

siendo

$$\mathbf{C} = \begin{bmatrix} 1 & 0 & \dots & 0 & -1 \\ 0 & 1 & \dots & 0 & -1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & -1 \end{bmatrix}_{(p-1) \times p}$$

- **Solución del problema**

- Transformar los datos $\underline{Y}_1 = \mathbf{C}\underline{X}_1, \dots, \underline{Y}_n = \mathbf{C}\underline{X}_n$
- Realizar el contraste

$$H_0 : \mu_{\underline{Y}} = \mathbf{0}$$

5.3.2 Test para la simetría

- Consideremos n individuos de una población, sobre los que se consideran p magnitudes o características en una situación A y las mismas magnitudes en otra situación B .
- Puede considerarse la siguiente modelización:

– $\underline{X} = (X_1, \dots, X_{2p})'$, de forma que X_1, \dots, X_p medidas de p magnitudes en la situación A y X_{p+1}, \dots, X_{2p} medidas de las mismas magnitudes en la situación B .

* X_i y X_{i+p} , $i = 1, \dots, p$ corresponden a la misma magnitud en situaciones A y B .

– $\underline{X} \sim N_{2p}[\underline{\mu}, \underline{\Sigma}]$ donde

$$\underline{\mu} = \left[\underbrace{\mu_1, \dots, \mu_p}_A, \underbrace{\mu_{p+1}, \dots, \mu_{2p}}_B \right]'$$

– $\underline{X}_1, \dots, \underline{X}_n$ m.a. de \underline{X}

- La hipótesis de interés es

$$H_0 : \mu_i = \mu_{i+p} \quad i = 1, \dots, p$$

- Equivalentemente

$$H_0 : \underline{A}\underline{\mu} = \underline{0}$$

donde $\underline{A} = [\underline{I}_p \quad -\underline{I}_p]$.

- **Solución del problema**

– Transformar los datos $\underline{Y}_1 = \underline{A}\underline{X}_1, \dots, \underline{Y}_n = \underline{A}\underline{X}_n$

– Realizar el contraste

$$H_0 : \mu_{\underline{Y}} = \underline{0}$$

6 Contraste de hipótesis sobre la igualdad de medias de dos poblaciones

6.1 Caso unidimensional

- Muestras independientes: X_1, \dots, X_n de $N(\mu_1, \sigma_1^2)$ y Y_1, \dots, Y_m de $N(\mu_2, \sigma_2^2)$
- Hipótesis básica

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2$$

- Estadístico (supuesto $\sigma_1^2 = \sigma_2^2$) y distribución bajo H_0

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \stackrel{H_0}{\sim} t_{n+m-2}$$

con

$$S_p^2 = \frac{(n-1)S_{c1}^2 + (m-1)S_{c2}^2}{n+m-2}$$

- Región crítica a un nivel α

$$|T| \geq t_{n+m-2, 1-\alpha/2}$$

6.2 Caso multidimensional

- Dos **muestras independientes** procedentes de dos poblaciones normales p -variantes con la misma matriz de varianzas y covarianzas

$$\underline{X}_1, \underline{X}_2, \dots, \underline{X}_{n_1} \text{ i.i.d. } N_p(\underline{\mu}_1, \underline{\Sigma})$$
$$\underline{Z}_1, \underline{Z}_2, \dots, \underline{Z}_{n_2} \text{ i.i.d. } N_p(\underline{\mu}_2, \underline{\Sigma})$$

- El problema fundamental a abordar es el contraste $H_0 : \underline{\mu}_1 = \underline{\mu}_2$.
- **Resultados previos y notación**

$$- \underline{\bar{X}} \sim N_p[\underline{\mu}_1, \frac{1}{n_1} \underline{\Sigma}],$$

$$- \underline{\bar{Z}} \sim N_p[\underline{\mu}_2, \frac{1}{n_2} \underline{\Sigma}]$$

$$- \mathbf{S}_1 = (n_1 - 1) \hat{\underline{\Sigma}}_1^{-1} = \sum_{j=1}^{n_1} (\underline{X}_j - \underline{\bar{X}}) (\underline{X}_j - \underline{\bar{X}})^t \sim W_p(n_1 - 1, \underline{\Sigma})$$

$$- \mathbf{S}_2 = (n_2 - 1) \hat{\underline{\Sigma}}_2^{-1} = \sum_{j=1}^{n_2} (\underline{Z}_j - \underline{\bar{Z}}) (\underline{Z}_j - \underline{\bar{Z}})^t \sim W_p(n_2 - 1, \underline{\Sigma})$$

– Sea

$$\mathbf{S}_p = \mathbf{S}_1 + \mathbf{S}_2$$

– La matriz

$$\hat{\underline{\Sigma}} = \frac{1}{n_1 + n_2 - 2} \mathbf{S}_p$$

es un estimador insesgado de $\underline{\Sigma}$.

Teorema

1. $\underline{\bar{X}} - \underline{\bar{Z}} \sim N_p \left(\underline{\mu}_1 - \underline{\mu}_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \underline{\Sigma} \right)$
2. $\mathbf{S}_1 + \mathbf{S}_2 \sim W_p(n_1 + n_2 - 2, \underline{\Sigma})$
3. $\underline{\bar{X}} - \underline{\bar{Z}}$ es independiente de $\mathbf{S}_1 + \mathbf{S}_2$
4. $\frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2} \left(\underline{\bar{X}} - \underline{\bar{Z}} - \left(\underline{\mu}_1 - \underline{\mu}_2 \right) \right)^t \mathbf{S}_p^{-1} \left(\underline{\bar{X}} - \underline{\bar{Z}} - \left(\underline{\mu}_1 - \underline{\mu}_2 \right) \right)^t \sim T_{p, n_1 + n_2 - 2}^2$

Teorema En las condiciones anteriores,

1. El estadístico del TRV para el contraste:

$$H_0 : \underline{\mu}_1 = \underline{\mu}_2 \quad vs. \quad H_1 : \underline{\mu}_1 \neq \underline{\mu}_2$$

viene dado por

$$T^2 = \frac{n_1 n_2 (n_1 + n_2 - 2)}{n_1 + n_2} \left[\underline{\bar{X}} - \underline{\bar{Z}} \right]^t \mathbf{S}_p^{-1} \left[\underline{\bar{X}} - \underline{\bar{Z}} \right]$$

2. Distribución bajo H_0

$$T^2 \stackrel{H_0}{\sim} T_{p, n_1 + n_2 - 2}^2.$$

o equivalentemente

$$F = \frac{(n_1 + n_2 - p - 1)}{p} \frac{n_1 n_2}{n_1 + n_2} \left[\underline{\bar{X}} - \underline{\bar{Z}} \right]^t \mathbf{S}_p^{-1} \left[\underline{\bar{X}} - \underline{\bar{Z}} \right] \stackrel{H_0}{\sim} \mathcal{F}_{p, (n_1 + n_2 - p - 1)},$$

3. Región crítica para un test de tamaño α

$$F \geq \mathcal{F}_{p, (n_1 + n_2 - p - 1), 1 - \alpha}.$$

6.3 Contraste para transformaciones lineales

Proposición. Sean dos muestras independientes:

$$\underline{X}_1, \underline{X}_2, \dots, \underline{X}_{n_1} \sim N_p[\underline{\mu}_1, \Sigma] ; \underline{Z}_1, \underline{Z}_2, \dots, \underline{Z}_{n_2} \sim N_p[\underline{\mu}_2, \Sigma]$$

y sea \mathbf{A} una matriz de dimensiones $m \times p$ ($m \leq p$), de rango m .

El estadístico del test de razón de verosimilitudes para el contraste:

$$H_0 : \mathbf{A}\underline{\mu}_1 = \mathbf{A}\underline{\mu}_2 \quad vs. \quad H_1 : \mathbf{A}\underline{\mu}_1 \neq \mathbf{A}\underline{\mu}_2$$

viene dado por:

$$F = \frac{(n_1 + n_2 - m - 1)}{m(n_1 + n_2 - 2)} \frac{n_1 n_2}{n_1 + n_2} \left[\mathbf{A}(\overline{\underline{X}} - \overline{\underline{Z}}) \right]^t (\mathbf{A}\mathbf{S}_p\mathbf{A}^t)^{-1} \left[\mathbf{A}(\overline{\underline{X}} - \overline{\underline{Z}}) \right]$$

y

$$F \stackrel{H_0}{\sim} \mathcal{F}_{m, (n_1 + n_2 - m - 1)}$$

6.3.1 Análisis de perfiles de dos poblaciones.

Consideremos una batería de p magnitudes medidas sobre muestras de tamaño n_1 y n_2 , obtenidas de dos poblaciones con vectores medias $\underline{\mu}_1 = (\mu_{11}, \dots, \mu_{1p})^t$ y $\underline{\mu}_2 = (\mu_{21}, \dots, \mu_{2p})^t$, respectivamente.

El gráfico obtenido por la unión de los puntos $(1, \mu_{11}), (2, \mu_{12}), \dots, (p, \mu_{1p})$ se denomina *perfil de la primera población*.

Análogamente, la unión de los puntos $(1, \mu_{21}), (2, \mu_{22}), \dots, (p, \mu_{2p})$ constituye el perfil de la segunda población.

- Cuestiones de interés sobre los perfiles
 - ¿Son paralelos?
 - ¿Tienen idéntico perfil medio?

- **Paralelismo de perfiles**

La hipótesis de paralelismo se puede expresar como

$$H_0 : \mu_{1k} - \mu_{1(k-1)} = \mu_{2k} - \mu_{2(k-1)} \quad \forall k = 2, \dots, p$$

o equivalentemente

$$H_0 : \mathbf{A}\underline{\mu}_1 = \mathbf{A}\underline{\mu}_2$$

donde

$$\mathbf{A} = \begin{bmatrix} -1 & 1 & 0 & \dots & 0 & 0 \\ 0 & -1 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & -1 & 1 \end{bmatrix} \in \mathcal{M}_{(p-1) \times p}$$

- **Mismo perfil medio**

La hipótesis se puede expresar como

$$H_0 : \frac{1}{p} \sum_{i=1}^p \mu_{1i} = \frac{1}{p} \sum_{i=1}^p \mu_{2i} \Leftrightarrow H_0 : 1_p \underline{\mu}_1 = 1_p \underline{\mu}_2$$

donde

$$1_p = [1 \dots 1] \in \mathcal{M}_{1 \times p}$$